

Statistica

Combinatoria

- *Combinazioni:*

$$C_n^m = \binom{m}{n} = \frac{m!}{n!(m-n)!}$$

Utile per: estrazioni **SENZA** ripetizione, **NO** ordine.

- *Disposizioni semplici (senza ripetizione):*

$$D_n^m = \frac{m!}{(m-n)!}$$

Utile per: estrazioni **SENZA** ripetizione, **CON** ordine.

- *Disposizioni con ripetizione:*

$$m^n$$

Utile per: estrazioni **CON** ripetizione, **CON** ordine.

- *Permutazioni:*

$$m!$$

Utile per: estrazioni **SENZA** ripetizione, **CON** ordine.

Probabilità

- *Definizione classica di probabilità:*

$$P(E) = \frac{|E|}{|\Omega|}$$

Dove E sono gli **eventi favorevoli**, Ω è lo spazio dei campioni (**tutti gli eventi possibili**). Questa definizione è utilizzabile nel caso in cui gli **eventi elementari sono equiprobabili** e Ω ha **cardinalità finita**.

- *Probabilità condizionale di A da in B*

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Restituisce la **probabilità** di A quando sappiamo che B si è **verificato**. È come se B diventasse spazio dei campioni.

- *Formula delle probabilità totali:* siano $A, B_1, \dots, B_n \in \mathcal{F}$ t.c. i vari B sono a 2-2 disgiunti, allora

$$P(A) = \sum_{i=1}^n P(A|B_i)P(B_i)$$

Utile per **calcolare le probabilità di un evento (A)** sapendo che **esistono diversi scenari (B_i)** in cui esso può accadere.

- *Teorema di Bayes*: nelle stesse ipotesi precedenti

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{\sum_{i=1}^n P(A|B_i)P(B_i)}$$

O, nel caso di una sola ipotesi:

$$P(B|A) = \frac{P(A|B)P(B)}{P(A)}$$

Utile a calcolare le **probabilità di una causa, sapendo l'effetto**.

Indicazioni operative varie

1. Se hai un esercizio in cui sai che hai a che fare con probabilità condizionata, guarda il tipo di esercizio:
 - se **costruisci un evento passo passo** (es: pesco una cosa, POI pesco un'altra) allora usare una formula del tipo $P(A) \cdot P(B|A)$ dove $P(B|A)$ la si intuisce al volo;
 - se possiedi i dati già in principio e devi solo **filtrare una cosa specifica**, allora usa la formula della divisione $P(A \cap B)P(B)$.
2. Fai molta attenzione alla traccia, **non cascare in errori dovuti alla comprensione** sbagliata. Es:
 - "Qual è la probabilità che la 5^a chiave sia quella giusta?"
 - "Ho già provato 4 chiavi e non andavano. Qual è la probabilità che la 5^a sia giusta?"
sono domande diverse, quindi soluzioni diverse.

Variabili aleatorie

Associano ad ogni evento un numero reale ($E \in \Omega \rightarrow x \in \mathbb{R}$). Possono essere **discrete** (quando la x può assumere un insieme finito e numerabile di valori tale che $\sum_{i=1}^n P_i = 1$) o **continue** (quando le probabilità si esprimono in termini di area).

Alle variabili aleatorie *discrete* si associa:

- una **funzione di probabilità** $P(x_i)$: restituisce la probabilità per una x_i ;
- **funzione di ripartizione** (o accumulazione) $F(x_i)$: somma tutte le varie probabilità fino ad ottenere 1.

Alle variabili aleatorie *continue* si associa:

- una **funzione di probabilità** $P(x_i)$;

- una **funzione di densità di probabilità** $f(x)$: equivalente della funzione di accumulazione;

Esempi di v.a. discrete: *Bernoulli, binomiale, geometrica*; Esempi di v.a. continue: *Normale, t-Student, Chi-quadro, Uniforme, Fisher*.

V.A. Discrete

V.A. di Bernoulli

Utile per casi di tipo successo-insuccesso (S-I).

$$X = \{1 \text{ se ho S } 0 \text{ se ho I} \quad \text{cod}(X) = 0, 1$$

dove:

- $P(X=1)=p$
- $P(X=0)=1-p$

si scrive $X \sim b(1,p)$ e si dice *v.a. di Bernoulli con parametro p*.

- $E(X)=p$
- $V(X)=p(1-p)$

V.A. binomiale

Utile per i casi di ripetizioni (indipendenti) di esperimenti di tipo S-I dove la probabilità di S è pari a $p \in (0,1)$. Voglio determinare la v.a. X che **conta il numero di S nelle n prove**, pertanto $\text{cod}(X)=0,1,\dots,n$. Se $k=0,\dots,n$ $P(X=k)$ è la **probabilità che ci siano esattamente k successi**, quindi:

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

si scrive $X \sim b(n,p)$ e si dice *v.a. a legge binomiale di parametri n,p*.

- $E(X)=np$
- $V(X)=np(1-p)$

V.A. Geometrica

Utile per casi di ripetizioni (indipendenti) di esperimenti di tipo S-I per un numero imprecisato di volte, dove $p \in (0,1)$ è la probabilità di S in ogni singola prova, e vogliamo sapere quale v.a. X descrive le **probabilità di primo successo**. Se $k=1,2,\dots$ $P(X=k)$ è la probabilità che il primo successo si verifichi esattamente alla k-esima prova, pertanto $\text{cod}(X)=1,2,3,\dots$

$$P(X = k) = p(1-p)^{k-1}, \quad k \geq 1$$

si scrive $X \sim \text{geo}(p)$ e si dice *v.a. geometrica di parametro p*.

- $E(X)=1p$
- $V(X)=1-pp2$

V.A. Poisson

Una v.a. si dice che ha **legge di Poisson di parametro λ** ($\lambda>0$), e si scrive $X\sim P(\lambda)$ se:

- $\text{cod}(X)=N\cup 0=0,1,2,\dots;$
- $P(X=k)=e^{-\lambda}\lambda^k/k!, k\geq 0.$

Questa v.a. è **associabile alla binomiale** se, data $X\sim b(n,p)$ con **n "grande"** e **p piccola** t.c. $np=\lambda$, allora X si può approssimare con una Poisson di parametro λ ($X\approx P(\lambda), \lambda=np$). Utile per **semplificare i calcoli**.

- $E(X)=\lambda$
- $V(X)=\lambda$

V.A. Continue

V.A. Uniforme

Siano $a,b\in\mathbb{R}, a<b$. Si dice che una v.a. X ha *legge uniforme di parametri a, b* e si scrive $X\sim U(a,b)$ se X è assolutamente continua e con funzione di densità di probabilità (pdf):

$$f_X(x) := \begin{cases} \frac{1}{b-a} & a \leq x \leq b \\ 0 & \text{altrimenti} \end{cases}$$

Essa ha funzione di distribuzione (FdD):

$$F_X(x) = \int_{-\infty}^x f_X(t)dt = \begin{cases} 0 & \text{se } x < a \\ \frac{x-a}{b-a} & \text{se } a \leq x \leq b \\ 1 & \text{se } x > b \end{cases}$$

La probabilità che prende valori in un intervallo **dipende solo dalla sua ampiezza**, NON da dove si trova l'intervallo stesso, ecco perché si dice *uniforme*.

- $E(X)=\frac{1}{2}(a+b)$
- $V(X)=\frac{1}{12}(b-a)^2$

V.A. Gaussiana (o normale)

Siano $\mu\in\mathbb{R}$ e $\sigma>0$. Si dice che una v.a. X ha *legge gaussiana di parametri μ e σ^2* e si scrive $X\sim N(\mu,\sigma^2)$ se X è assolutamente continua con funzione di densità di probabilità (pdf):

$$f_X(x) := \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Essa ha funzione di distribuzione (FdD):

$$F_X(x) = \int_{-\infty}^x f_X(t)dt$$

la più importante legge gaussiana è quella per cui $\mu=0, \sigma^2=1$, cioè $X \sim N(0,1)$; in tal caso si dice che X ha **legge normale standard**. la FdD di una normale standard si denota con $\Phi(x)$.
Oss: $\Phi(-x)=1-\Phi(x)$

Proposizione:

$$aX + b \sim N(a\mu + b, a^2\sigma^2)$$

Come convertiamo una normale ad una normale standard?

Sia $X \sim N(\mu, \sigma^2)$. Allora

$$\frac{X - \mu}{\sigma} \sim N(0, 1)$$

Se abbiamo i parametri μ e σ , come convertiamo una normale standard a una normale con quei parametri?

Se $X \sim N(0,1)$, allora, se $\mu \in \mathbb{R}, \sigma > 0$:

$$\sigma X + \mu \sim N(\mu, \sigma^2)$$

Se $X \sim N(0,1)$:

- $E(X)=\mu=0$
- $V(X)=\sigma^2=1$

Se $Y \sim N(\mu, \sigma^2)$ e $X \sim N(0,1)$, allora:

- $E(Y)=E(\sigma X + \mu)=\sigma E(X) + \mu$
- $V(Y)=E(\sigma X + \mu)=\sigma^2 V(X)$

V.A. Chi-quadro

Siano $X_1, \dots, X_n$ v.a. indipendenti, $X_i \sim N(0,1) \forall i=1, \dots, n$. Allora, detta $X = X_1^2 + X_2^2 + \dots + X_n^2$, si dice che X ha *legge Chi-quadro con n gradi di libertà (o di parametro n)* e si scrive $X \sim \chi_n^2$.
Oss:

$$X \sim N(0,1) \Rightarrow X^2 \sim \chi_1^2$$

- $E(X)=n$
- $V(X)=2n$

V.A. t-student

Siano $X \sim N(0,1)$ e $Y \sim \chi_n^2$ indipendenti. La v.a. $T = \frac{X}{\sqrt{Y/n}}$ si dice a *legge t-student con n gradi di libertà*, e si scrive $T \sim t_n$. Oss: è surrogato della normale, la sua pdf è simile alla funzione di Gauss.

- $E(X)=0$

- $V(X) = n - 2$

V.A. Fisher

Siano $X \sim \chi^2_n$ e $Y \sim \chi^2_m$ indipendenti. La v.a.

$$F := \frac{X/n}{Y/m}$$

si dice a *legge di Fisher con n,m gradi di libertà, e si scrive $F \sim F_{n,m}$.

lasciamo stare $E(X)$ e $V(X)$

Medie, varianze e operazioni su esse

Il **valore atteso** di X $E(X)$ è definito come segue:

- per v.a. discrete avremo:

$$:= \left\{ \sum_{k \in \text{cod}(X)} k P(X = k) \quad \text{se tale somma è finita} \quad + \infty \text{ altrimenti} \right.$$

- per v.a. continue avremo:

$$:= \left\{ \int_{-\infty}^{+\infty} t f_X(t) dt \quad \text{se tale integrale è definito} \quad + \infty \text{ altrimenti} \right.$$

Proposizioni varie:

- $E(aX + b) = aE(X) + b$
- se $X_1, \dots, X_n$ v.a. t.c. $E(X_i) < +\infty \quad \forall i=1, \dots, n$, allora $E(\sum_{i=1}^n X_i) = \sum_{i=1}^n E(X_i)$
- se $X_1, \dots, X_n$ v.a. indipendenti t.c. $E(X_i) < +\infty \quad \forall i=1, \dots, n$, allora $E(\prod_{i=1}^n X_i) = \prod_{i=1}^n E(X_i)$
- se X v.a. , $m \geq 1$, si definisce **momento di ordine m** di X la quantità $X_n =$

$$= \left\{ \sum_{k \in \text{cod}(X)} k^m P(X = k) \quad \text{per v.a. discrete} \quad \int_{-\infty}^{+\infty} t^m f_X(t) dt \quad \text{per v.a. continue} \right.$$

La varianza di X $V(X)$ è definita come segue:

$$V(X) := E[(X - E(X))^2]$$

La covarianza di X, Y è definita come segue:

$$\text{cov}(X, Y) := E[(X - E(X))(Y - E(Y))]$$

e se $X=Y$, allora:

$$\text{cov}(X, X) = E[(X - E(X))^2] = V(X)$$

Formula operativa della covarianza:

$$\text{cov}(X, Y) = E(XY) - E(X) E(Y)$$

Proposizioni varie:

- $V(X) = E(X^2) - E(X)^2$ (formula operativa della varianza)
- $V(aX+b) = a^2 V(X)$ (la traslazione b non cambia la disp. intorno alla media)
- se $X_1, \dots, X_n$ v.a. t.c. $E(X_i) < +\infty \quad \forall i=1, \dots, n$, allora: $V(\sum_{i=1}^n X_i) = \sum_{i=1}^n V(X_i) + \sum_{i,j=1, i \neq j}^n \text{cov}(X_i, X_j)$
- se $X_1, \dots, X_n$ v.a. indipendenti, allora:

$$V\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n V(X_i)$$

Covarianza

La **covarianza** è una misura che descrive la **dipendenza lineare** tra due variabili aleatorie X e Y , indicando se tendono a variare **nella stessa direzione** o in **direzioni opposte**.

Definizione

Siano X, Y due variabili aleatorie con valore atteso finito.

La covarianza è definita come:

$$\text{cov}(X, Y) = E[(X - E(X))(Y - E(Y))]$$

Se $X=Y$, si ottiene:

$$\text{cov}(X, X) = E[(X - E(X))^2] = V(X)$$

👉 La varianza è quindi un **caso particolare** della covarianza.

Formula operativa

Se $E(X^2), E(Y)^2$ ed $E(XY)$ sono finite :

$$\text{cov}(X, Y) = E(XY) - E(X)E(Y)$$

Interpretazione del segno

- $\text{cov}(X, Y) > 0$: X e Y tendono a crescere o decrescere insieme
- $\text{cov}(X, Y) < 0$: quando una cresce, l'altra tende a decrescere
- $\text{cov}(X, Y) = 0$: assenza di dipendenza lineare

Proprietà principali

- Simmetria:

$$\text{cov}(X, Y) = \text{cov}(Y, X)$$

- Linearità:

$$\text{cov}(aX + b, cY + d) = ac \text{cov}(X, Y)$$

- Se X e Y sono indipendenti:

$$\text{cov}(X, Y) = 0$$

Collegamento con la varianza della somma

Per v. a $X_1, \dots, X_n$ con varianza finita :

$$\text{Se le v. a sono indipendenti } V\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n V(X_i)$$

$$\text{Se le v. a sono indipendenti : } V\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n V(X_i)$$

Limiti della covarianza

- Dipende dalle unità di misura
- Non è normalizzata
- Non consente confronti diretti tra coppie diverse di variabili

Per questo si introduce la correlazione:

$$\rho_{X,Y} = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y} \in [-1, 1]$$

Legge dei grandi numeri

La **Legge dei Grandi Numeri** dice sostanzialmente una cosa molto intuitiva:

Se fai molti esperimenti indipendenti e identici tra loro, la media dei risultati si avvicinerà sempre di più al valore atteso vero della variabile aleatoria

In altre parole: più dati raccogli, più la media campionaria sembra “giusta”.

👉 Per esempio, se lanci una moneta tantissime volte, la percentuale di teste tenderà verso il suo valore teorico 0,50

Formula della media campionaria:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

Legge debole dei grandi numeri (LGND)

$$\lim_{n \rightarrow \infty} \Pr\left(|\bar{X}_n - \mu| < \epsilon\right) = 1$$

Legge forte dei grandi numeri (LGNF)

$$\Pr\left(\lim_{n \rightarrow \infty} \bar{X}_n = \mu\right) = 1$$

Teorema del limite centrale (TLC)

Idea base:

Se sommi o fai la media di tante variabili casuali **indipendenti e identicamente distribuite**, allora la distribuzione della somma (o della media) **tenderà ad essere normale**, anche se le singole variabili non sono normali.

In poche parole:

- Non importa come sono distribuite le variabili originali
- Se il numero di osservazioni n è grande, la media campionaria $\bar{X}_n$ si comporta come una variabile normale
- Questo è fondamentale per fare inferenza statistica, costruire intervalli di confidenza, test, ecc...

Formule principali

- Se $X_1, X_2, \dots, X_n$ sono variabili indipendenti con:
 - media $\mu = E(X_i)$
 - varianza $\sigma^2 = V(X_i)$
- Allora la somma normalizzata:

$$S_n = \frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} \xrightarrow{n \rightarrow \infty} \mathcal{N}(0, 1)$$

Intuizione pratica

- Se lanci 100 dadi, la somma dei risultati è **quasi normale** anche se un singolo dado è uniformemente distribuito
- Se fai molti esperimenti, puoi usare la **distribuzione normale per approssimare probabilità e intervalli di confidenza**
- È il motivo per cui la distribuzione normale appare ovunque in statistica

Statistica inferenziale (matematica)

La **statistica** è la disciplina che studia come raccogliere, descrivere e interpretare dati.

Si divide in due grandi branche:

- **Statistica descrittiva**, che ha lo scopo di riassumere e descrivere i dati osservati (medie, varianze, grafici, quantili), senza trarre conclusioni generali.
- **Statistica inferenziale**, che utilizza un **campione** per trarre conclusioni su una **popolazione** più ampia, facendo uso di modelli probabilistici.

La statistica inferenziale nasce dall'esigenza di studiare fenomeni complessi quando non è possibile osservare l'intera popolazione, ma solo una parte di essa.

Campione e numerosità

Si considera un **campione casuale** costituito da n osservazioni:

$$X_1, X_2, \dots, X_n$$

dove le X_i sono variabili aleatorie indipendenti e identicamente distribuite.

La quantità n prende il nome di **numerosità del campione** e rappresenta il numero di osservazioni disponibili.

La numerosità è fondamentale perché influisce sull'affidabilità delle conclusioni: in generale, all'aumentare di n , le inferenze diventano più precise.

Statistiche

Una **statistica** è una funzione del campione che **non dipende da parametri ignoti della popolazione**.

Formalmente, una statistica è una funzione del tipo:

$$T = T(X_1, \dots, X_n)$$

Poiché dipende da variabili aleatorie, una statistica è **essa stessa una variabile aleatoria**. Questo è un punto concettuale centrale: le quantità che calcoliamo sui dati (come la media o la varianza campionaria) non sono numeri fissi, ma variano da campione a campione

Media campionaria

La **media campionaria** è definita come:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

Essa è una statistica e viene utilizzata per stimare il valore atteso (media) della popolazione. Grazie alla **legge dei grandi numeri**, la media campionaria converge al valore atteso vero quando la numerosità del campione cresce.

Varianza campionaria

La **varianza campionaria** misura la dispersione dei dati attorno alla media campionaria ed è definita come:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Il denominatore $n - 1$ viene utilizzato per rendere la varianza campionaria uno **stimatore non distorto** della varianza della popolazione, cioè:

$$E(S^2) = \sigma^2$$

Anche la varianza campionaria è una statistica e quindi una variabile aleatoria

Significato complessivo

In statistica inferenziale si introducono statistiche (come media e varianza campionaria) che, essendo funzioni del campione, sono variabili aleatorie.

Lo studio delle loro proprietà probabilistiche consente di stimare parametri ignoti della popolazione e di valutare l'incertezza associata a tali stime.

Questo approccio costituisce la base per lo sviluppo di:

- stimatori
- intervalli di confidenza
- test d'ipotesi

Gli Stimatori

Il problema statistico

Sia dato un campione casuale

$$X_1, \dots, X_n$$

di variabili aleatorie indipendenti e identicamente distribuite, la cui distribuzione dipende da un parametro ignoto θ .

Lo scopo della statistica inferenziale è **stimare il parametro θ** a partire dal campione osservato.

Definizione di stimatore

Uno **stimatore di θ** è una **statistica**, cioè una funzione del campione:

$$\hat{\theta} = T(X_1, \dots, X_n)$$

utilizzata per stimare il parametro ignoto θ

Poiché dipende dal campione, lo stimatore è una variabile aleatoria

Il valore numerico assunto dopo l'osservazione dei dati si chiama **stima**.

Se la stima è un singolo numero, lo stimatore è detto **puntuale**.

Stimatore non distorto (corretto)

Uno stimatore puntuale $\hat{\theta}$ è detto **non distorto** o **corretto** se:

$$E(\hat{\theta}) = \theta$$

Esempi

- $E(\bar{X}) = \mu \Rightarrow$ la media campionaria è stimatore non distorto di μ
- $E(S^2) = \sigma^2 \Rightarrow$ la varianza campionaria è stimatore non distorto di σ

Stimatore consistente

Uno stimatore puntuale $\hat{\theta}$ è detto consistente se:

$$\forall \epsilon > 0, \quad \lim_{n \rightarrow \infty} P(|\hat{\theta} - \theta| > \epsilon) = 0$$

Cioè, al crescere della numerosità del campione, lo stimatore converge in probabilità al parametro vero

Stimatori di massima verosimiglianza (MV)

1) Problema

- Campione $X = (X_1, \dots, X_n)$ con $X \sim D(\theta)$ θ **ignoto**.
- Obiettivo: stimare **puntualmente** θ dai dati osservati $X_1, \dots, X_n$.

2) Idea principale

- Se ho osservato $X_1, \dots, X_n$ questi dati sono i più probabili da osservare sotto un certo valore di θ
- Lo stimatore MV $\hat{\theta}$ è il valore di θ che rende massima la probabilità di osservare il campione raccolto

$$\hat{\theta} = \arg \max_{\theta} L(\theta)$$

3) Funzione di verosimiglianza $L(\theta)$

Caso discreto

$$L(\theta) = P_{\theta}(X_1 = x_1, \dots, X_n = x_n) = P_{\theta}(X_1 = x_1) \cdot \dots \cdot P_{\theta}(X_n = x_n)$$

Caso continuo

$$L(\theta) = f_{X_1}(x_1; \theta) \cdot f_{X_2}(x_2; \theta) \cdot \dots \cdot f_{X_n}(x_n; \theta) = \prod_{i=1}^n f_{X_i}(x_i; \theta)$$

- In entrambi i casi $L(\theta)$ restituisce la probabilità di osservare i dati
- Lo stimatore $\hat{\theta}$ massimizza $L(\theta)$

4) Passaggio al logaritmo

- Derivare un prodotto può essere complicato.
- Poiché il logaritmo è monotono crescente:

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^n \log f_{X_i}(x_i; \theta)$$

- La posizione del massimo non cambia: $\hat{\theta} = \arg \max_{\theta} \ell(\theta)$

- Si passa da un **prodotto di probabilità** a una **somma di logaritmi**, più semplice da derivare.

5. Procedura per trovare $\hat{\theta}$

1. Scrivere $L(\theta)$ dal campione osservato.
2. Passare a $\ell(\theta) = \log L(\theta)$
3. Derivare rispetto a θ e porre uguale a 0:

$$\frac{d\ell(\theta)}{d\theta} = 0$$

4. Risolvere per θ (verificare che sia un massimo).

Test sulla media di un campione normale

Impostazione del problema

- Sia $X_1, \dots, X_n$ un campione di i.i.d
- $X_i \sim N(\mu, \sigma^2)$
- La varianza σ^2 può essere nota oppure ignota
- Vogliamo verificare un'ipotesi sul valore della **media** μ

Ipotesi statistiche

Si fissano:

- **Ipotesi nulla** $H_0 : \mu = \mu_0$
- **Ipotesi alternativa** H_1 , che può essere:
 - bilaterale: $\mu \neq \mu_0$
 - unilaterale destra: $\mu > \mu_0$
 - unilaterale sinistra: $\mu < \mu_0$

Statistica test

Lo stimatore naturale della media è la **media campionaria**:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

Per costruire il test, si standardizza la media campionaria

Caso 1: varianza nota (σ^2 nota) -- Z-test

Statistica test

$$Z = \frac{\bar{X} - \mu_0}{\sigma / \sqrt{n}}$$

- Sotto H_0 , vale:

$$Z \sim N(0, 1)$$

Regione critica

Fissato un livello di significatività α :

- **Test bilaterale:**

$$|Z| > z_{1-\alpha/2}$$

- Test unilaterale destro:

$$Z > z_{1-\alpha}$$

- Test unilaterale sinistro:

$$Z < -z_{1-\alpha}$$

Caso 2: varianza ignota (σ^2 nota) -- t-test

Stimatore della varianza

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Statistica test

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$$

- Sotto H_0 :

$$T \sim t_{n-1}$$

(distribuzione t di Studenti con n - 1 gradi di libertà)

Test sulla varianza dei campioni gaussiani

Test di ipotesi sulla varianza di un campione normale

Quando si usa?

Hai un campione $X_1, \dots, X_n$ da una popolazione **normale** $N(\mu, \sigma^2)$ e vuoi **verificare se la varianza** σ^2 vale un certo valore σ_0^2

È un **test di ipotesi** per la varianza, non per la media

Ipotesi

Possibili formulazioni:

- bilaterale:

$$H_0 : \sigma^2 = \sigma_0^2 \text{ versus } H_1 : \sigma^2 \neq \sigma_0^2$$

- unilaterale destra:

$$H_0 : \sigma^2 = \sigma_0^2 \text{ versus } H_1 : \sigma^2 > \sigma_0^2$$

- unilaterale sinistra

$$H_0 : \sigma^2 = \sigma_0^2 \text{ versus } H_1 : \sigma^2 < \sigma_0^2$$

Tipo di ipotesi dipende da quello che vuoi verificare

Statistica test

Si usa la varianza campionaria corretta:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

La statistica che si costruisce è:

$$X^2 = (n-1) \frac{S^2}{\sigma_0^2}$$

Sotto l'ipotesi nulla H_0 vale che:

$$\chi^2 \sim \chi_{n-1}^2$$

cioè una **distribuzione chi-quadrato con $n-1$ gradi di libertà**

Regione critica

Dato un livello di significatività α

Test bilaterale:

Si rifiuta H_0 se:

$$\chi^2 < \chi_{\frac{\alpha}{2}, n-1}^2 \text{ o } \chi^2 > \chi_{\frac{\alpha}{2}, n-1}^2$$

(Cioè se la statistica è troppo piccola o troppo grande rispetto alla chi-quadrato.)

Test unilaterale destro

Si rifiuta H_0 se:

$$\chi^2 > \chi_{\frac{\alpha}{2}, n-1}^2$$

Test unilaterale sinistro

Si rifiuta H_0 se:

$$\chi^2 < \chi_{\frac{\alpha}{2}, n-1}^2$$

Interpretazione

- Se il valore calcolato della statistica esce dalla **zona di valori “normali” sotto H_0** → si **rifiuta H_0** .
- Altrimenti **non si rifiuta H_0**

👉 Nel caso **bilaterale**, si controlla se la varianza osservata è **troppo diversa** da quella data.

👉 Nei casi **unilaterali**, si guarda se è **troppo grande** o **troppo piccola** rispetto a σ_0^2

Concetto conciso da memorizzare (per l'esame)

Test sulla varianza:

$$\chi^2 = (n-1) \frac{S^2}{\sigma_0^2} \sim \chi_{n-1}^2$$

Si confronta con i quantili della **chi-quadrato** per decidere se rifiutare H_0

Test di confronto per le medie dei campioni gaussiani

Test di confronto tra le medie di due campioni gaussiani

Situazione

- Due campioni **indipendenti**:

$$X_1, \dots, X_n \sim N(\mu_1, \sigma_1^2), Y_1, \dots, Y_m \sim N(\mu_2, \sigma_2^2)$$

- Obiettivo: confrontare le medie: μ_1 e μ_2

Ipotesi

- Ipotesi nulla:

$$H_0 : \mu_1 = \mu_2$$

- Ipotesi alternativa:
 - bilaterale: $\mu_1 \neq \mu_2$
 - unilaterale $\mu_1 > \mu_2$ oppure $\mu_1 < \mu_2$

Caso 1: varianze note

(meno comune, ma teoricamente semplice)

Statistica test

$$Z = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{m}}}$$

Distribuzione sotto H_0

$$Z \sim N(0, 1)$$

☞ Si confronta con i quantili della normale standard.

Caso 2: varianze ignote ma uguali

(caso classico più importante)

Varianza unita

$$S_p^2 = \frac{(n-1)S_X^2 + (m-1)S_Y^2}{n+m-2}$$

Statistica test

$$T = \frac{\bar{X} - \bar{Y}}{S_p \sqrt{\frac{1}{n} + \frac{1}{m}}}$$

Distribuzione sotto H_0

$$T \sim t_{n+m-2}$$

☞ Si usano le **tavole della t di Student**.

Test per il confronto delle varianze di due campioni normali

Situazione

- Due campioni indipendenti:

$$X_1, \dots, X_n \sim N(\mu_1, \sigma_1^2), Y_1, \dots, Y_m \sim N(\mu_2, \sigma_2^2)$$

- Obiettivo: confrontare le varianze σ_1^2 e σ_2^2

Ipotesi

- Ipotesi nulla:

$$H_0 : \sigma_1^2 = \sigma_2^2$$

- Ipotesi alternativa:
 - bilaterale: $\sigma_1^2 \neq \sigma_2^2$
 - unilaterale: $\sigma_1^2 > \sigma_2^2$
 - unilaterale: $\sigma_1^2 < \sigma_2^2$

Statistica test (test F)

Si usa il rapporto delle varianze campionarie:

$$F = \frac{S_X^2}{S_Y^2}$$

dove:

$$S_X^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, \quad S_Y^2 = \frac{1}{m-1} \sum_{i=1}^m (Y_i - \bar{Y})^2$$

Distribuzione sotto H_0

$$F \sim F_{n-1, m-1}$$

(distribuzione di Fisher con $n-1$ e $m-1$ gradi di libertà)

Regione critica

- Test unilaterale destro

$$H_1 : \sigma_1^2 > \sigma_2^2$$

Si rifiuta H_0 se:

$$F > F_{1-\alpha, n-1, m-1}$$

- Test bilaterale

$$H_1 : \sigma_1^2 \neq \sigma_2^2$$

Si rifiuta H_0 se:

$$F < F_{\alpha/2, n-1, m-1} \quad oppure \quad F > F_{1-\alpha/2, n-1, m-1}$$

Osservazioni importanti (da esame)

- I campioni **devono essere normali**
- I campioni devono essere **indipendenti**
- Il test è **molto sensibile** alla non normalità
- Spesso si mette la **varianza più grande al numeratore** per usare solo la coda destra